Refinamento da MTDQ-12

Material Suplementar - Análises

Frederico Pedrosa e Cristiano Gomes

2026-11-02

Contents

1 Set up **1**

1.1 Instalação e Carregamento de Pacotes 1

1.2 Carregamento e Verificação Estrutural da Base 2

2 Etapa 1: Diagnóstico das Categorias Originais (20 Itens, 5 Pontos) **3**

3 Etapa 2: Recodificação das Categorias e Seleção de Modelo (PCM vs. RSM) **4**

3.1 Comparação Formal entre PCM e RSM 6

4 Etapa 3: Refinamento Iterativo e Poda de Itens **7**

5 Etapa 4: Calibração do Modelo Final Rasch PCM (MTDQ-12) **7**

5.1 Parâmetros de Dificuldade e Limiares da MTDQ-12 8

5.2 Confiabilidade de Separação e Mapa de Itens-Pessoas 9

6 Etapa 5: Invariância de Medida por Sexo (DIF) **10**

7 Etapa 6: Análise Fatorial Confirmatória e Confiabilidade Composta **11**

7.1 Estabilidade do Construto (Correlação com o Modelo Bifatorial Original) 12

1 Set up

1.1 Instalação e Carregamento de Pacotes

```
# Lista de pacotes necessários (foco na família Rasch)
pacotes <- c("eRm", "psych", "ggplot2", "gridExtra","lavaan", "semTools",
             "knitr", "dplyr", "reshape2", "RColorBrewer")

# Função para verificar e instalar pacotes se necessário
```

```r
instalar_se_necessario <- function(pacotes) {
  pacotes_faltando <- pacotes[!(pacotes %in% installed.packages()[,"Package"])]
  if(length(pacotes_faltando) > 0) {
    install.packages(pacotes_faltando, dependencies = TRUE)
  }
}

# Verificar e instalar pacotes faltando
instalar_se_necessario(pacotes)

# Carregar todos os pacotes
lapply(pacotes, library, character.only = TRUE)

# Carregando dados

dados <- readRDS("mtdq_limpo.rds")
```

1.2 Carregamento e Verificação Estrutural da Base

Carregamos o banco de dados original contendo as 20 variáveis (i1 a i20) registradas na escala Likert original de 5 pontos (1 = Nunca, 2 = Raramente, 3 = Às vezes, 4 = Muitas vezes, 5 = Sempre).

```r
# Certifique-se de que o arquivo 'mtdq_limpo.rds' está no mesmo diretório de trabalho
dados_original <- readRDS("mtdq_limpo.rds")

# Extração estrita dos 20 itens numéricos
itens_20 <- paste0("i", 1:20)
dados_20 <- dados_original[, itens_20]

# Tabela descritiva de frequência geral por categoria de resposta
tabela_freq <- table(unlist(dados_20))
prop_freq <- prop.table(tabela_freq) * 100

df_desc_cat <- data.frame(
  Categoria = names(tabela_freq),
  Frequencia_Absoluta = as.vector(tabela_freq),
  Porcentagem = round(as.vector(prop_freq), 2)
)

knitr::kable(
  df_desc_cat,
  caption = "Distribuição geral das respostas nas 5 categorias originais (20 itens, N = 220).",
  booktabs = TRUE
)
```

Table 1: Distribuição geral das respostas nas 5 categorias originais (20 itens, N = 220).

Categoria	Frequencia_Absoluta	Porcentagem
1	359	8.16
2	298	6.77

Categoria	Frequencia_Absoluta	Porcentagem
3	902	20.50
4	1211	27.52
5	1630	37.05

2 Etapa 1: Diagnóstico das Categorias Originais (20 Itens, 5 Pontos)

A primeira etapa avalia se a escala Likert original de 5 pontos apresenta monotonicidade nos limiares (*thresholds*). Estimamos os modelos de Créditos Parciais (PCM) e de Escala Graduada (RSM) para os 20 itens originais.

```
# Ajuste dos modelos com 5 categorias (dados_20)
pcm_20_5cat <- PCM(dados_20)
rsm_20_5cat <- RSM(dados_20)

# Extração de limiares e dificuldades
limiares_pcm_5cat <- thresholds(pcm_20_5cat)$threshtable[[1]]
limiares_rsm_5cat <- thresholds(rsm_20_5cat)$threshtable[[1]]

# Tabela consolidada comparativa (Tabela 1 do artigo)
tab1_rsm <- data.frame(
  Item = 1:20,
  Beta_RSM = round(limiares_rsm_5cat[, "Location"], 2),
  L1_RSM = round(limiares_rsm_5cat[, "Threshold 1"], 2),
  L2_RSM = round(limiares_rsm_5cat[, "Threshold 2"], 2),
  L3_RSM = round(limiares_rsm_5cat[, "Threshold 3"], 2),
  L4_RSM = round(limiares_rsm_5cat[, "Threshold 4"], 2)
)

tab1_pcm <- data.frame(
  Beta_PCM = round(limiares_pcm_5cat[, "Location"], 2),
  L1_PCM = round(limiares_pcm_5cat[, "Threshold 1"], 2),
  L2_PCM = round(limiares_pcm_5cat[, "Threshold 2"], 2),
  L3_PCM = round(limiares_pcm_5cat[, "Threshold 3"], 2),
  L4_PCM = round(limiares_pcm_5cat[, "Threshold 4"], 2)
)

tab1_consolidada <- cbind(tab1_rsm, tab1_pcm)

knitr::kable(
  tab1_consolidada,
  caption = "Tabela 1: Dificuldade e limiares dos itens estimados pelos modelos RSM e PCM (5 categorias)",
  booktabs = TRUE,
  row.names = FALSE
)
```

Table 2: Tabela 1: Dificuldade e limiares dos itens estimados pelos modelos RSM e PCM (5 categorias).

Item	Beta_RSM	L1_RSM	L2_RSM	L3_RSM	L4_RSM	Beta_PCM	L1_PCM	L2_PCM	L3_PCM	L4_PCM
1	0.36	0.37	-0.48	0.62	0.94	0.52	0.63	-0.51	1.35	0.61
2	-0.17	-0.16	-1.01	0.08	0.40	0.05	0.77	-1.57	0.33	0.69
3	0.19	0.20	-0.64	0.45	0.77	0.40	0.68	-0.95	0.70	1.16
4	-0.14	-0.13	-0.98	0.11	0.43	0.18	0.49	-0.09	0.15	0.16
5	0.10	0.11	-0.74	0.36	0.68	0.35	0.80	-0.82	0.44	0.97
6	-0.08	-0.07	-0.91	0.18	0.50	0.05	-0.42	-0.48	0.39	0.70
7	0.07	0.08	-0.77	0.32	0.64	0.07	-0.74	-0.67	0.76	0.94
8	0.13	0.14	-0.71	0.39	0.71	0.37	0.69	-0.54	0.49	0.83
9	0.44	0.45	-0.40	0.70	1.02	0.65	0.83	-0.37	0.93	1.20
10	0.12	0.13	-0.72	0.37	0.69	0.28	0.14	-0.70	0.60	1.07
11	0.01	0.02	-0.83	0.27	0.59	0.10	-0.40	-0.66	0.63	0.82
12	0.50	0.52	-0.33	0.76	1.08	0.67	0.80	0.74	0.81	0.32
13	0.14	0.15	-0.70	0.39	0.71	0.35	0.41	-0.46	0.49	0.95
14	-0.34	-0.33	-1.18	-0.09	0.23	-0.18	-0.62	-0.42	-0.14	0.48
15	-0.26	-0.25	-1.10	-0.01	0.31	-0.35	-1.18	-1.19	-0.03	1.00
16	-0.05	-0.04	-0.89	0.21	0.53	0.08	-0.36	-0.52	0.21	0.99
17	-0.38	-0.37	-1.22	-0.12	0.20	-0.10	0.36	-1.13	0.05	0.32
18	-0.46	-0.45	-1.30	-0.21	0.11	-0.28	-0.74	-0.46	-0.08	0.19
19	-0.35	-0.34	-1.19	-0.10	0.22	-0.23	-0.23	-1.37	0.15	0.51
20	-0.04	-0.03	-0.88	0.21	0.53	0.07	-0.08	-1.02	0.52	0.87

Como observado na Tabela 1, o primeiro limiar é sistematicamente superior ao segundo ($l1 > l2$) em ambos os modelos, evidenciando desordem de limiares: os participantes não discriminam adequadamente as opções 1 (Nunca) e 2 (Raramente).

3 Etapa 2: Recodificação das Categorias e Seleção de Modelo (PCM vs. RSM)

Conforme a literatura psicométrica, colapsamos as categorias adjacentes problemáticas (1 e 2 tornam-se 1; 3 vira 2; 4 vira 3; 5 vira 4). A escala passa a ter 4 categorias de resposta (3 limiares).

```
# Recodificação dos 20 itens
recodificar_4cat <- function(x) {
  dplyr::case_when(
    x %in% c(1, 2) ~ 1,
    x == 3         ~ 2,
    x == 4         ~ 3,
    x == 5         ~ 4,
    TRUE           ~ NA_real_
  )
}

dadotr <- as.data.frame(lapply(dados_20, recodificar_4cat))

# Ajuste dos modelos com 4 categorias
pcm_20_4cat <- PCM(dadotr)
```

```r
rsm_20_4cat <- RSM(dadotr)

# Limiares obtidos após colapso (Tabela 2 do artigo)
lim_pcm_4cat <- thresholds(pcm_20_4cat)$threshtable[[1]]
lim_rsm_4cat <- thresholds(rsm_20_4cat)$threshtable[[1]]

tab2_comparativa <- data.frame(
  Item = 1:20,
  Beta_RSM = round(lim_rsm_4cat[, "Location"], 2),
  L1_RSM   = round(lim_rsm_4cat[, "Threshold 1"], 2),
  L2_RSM   = round(lim_rsm_4cat[, "Threshold 2"], 2),
  L3_RSM   = round(lim_rsm_4cat[, "Threshold 3"], 2),
  Beta_PCM = round(lim_pcm_4cat[, "Location"], 2),
  L1_PCM   = round(lim_pcm_4cat[, "Threshold 1"], 2),
  L2_PCM   = round(lim_pcm_4cat[, "Threshold 2"], 2),
  L3_PCM   = round(lim_pcm_4cat[, "Threshold 3"], 2)
)

knitr::kable(
  tab2_comparativa,
  caption = "Tabela 2: Dificuldade e limiares após recodificação para 4 categorias.",
  booktabs = TRUE,
  row.names = FALSE
)
```

Table 3: Tabela 2: Dificuldade e limiares após recodificação para 4 categorias.

Item	Beta_RSM	L1_RSM	L2_RSM	L3_RSM	Beta_PCM	L1_PCM	L2_PCM	L3_PCM
1	0.92	0.42	0.98	1.37	0.56	0.02	1.18	0.49
2	0.31	-0.19	0.37	0.76	-0.09	-0.96	0.13	0.56
3	0.74	0.23	0.80	1.18	0.39	-0.39	0.52	1.04
4	0.29	-0.21	0.35	0.74	0.11	0.37	-0.05	0.02
5	0.61	0.10	0.66	1.05	0.30	-0.19	0.25	0.84
6	0.44	-0.06	0.50	0.89	0.12	-0.40	0.21	0.57
7	0.64	0.13	0.69	1.08	0.24	-0.68	0.59	0.82
8	0.64	0.13	0.69	1.08	0.35	0.02	0.31	0.71
9	1.01	0.51	1.07	1.46	0.70	0.25	0.76	1.08
10	0.66	0.16	0.72	1.11	0.32	-0.41	0.42	0.95
11	0.55	0.05	0.61	1.00	0.19	-0.58	0.45	0.70
12	1.03	0.53	1.09	1.47	0.72	1.33	0.63	0.20
13	0.66	0.16	0.72	1.10	0.36	-0.05	0.31	0.82
14	0.13	-0.37	0.19	0.58	-0.14	-0.44	-0.33	0.34
15	0.25	-0.25	0.31	0.70	-0.27	-1.45	-0.22	0.86
16	0.48	-0.02	0.54	0.92	0.15	-0.42	0.03	0.86
17	0.07	-0.43	0.13	0.51	-0.25	-0.76	-0.16	0.17
18	0.00	-0.51	0.05	0.44	-0.26	-0.53	-0.29	0.04
19	0.13	-0.38	0.18	0.57	-0.33	-1.31	-0.05	0.37
20	0.48	-0.02	0.54	0.93	0.08	-0.83	0.34	0.75

3.1 Comparação Formal entre PCM e RSM

Comparamos os dois modelos via Teste de Razão de Verossimilhança (LR Test) e critérios de informação (AIC e BIC sob verossimilhança condicional), além de testes de invariância de Wald no nível do item.

```
pp_pcm_20 <- person.parameter(pcm_20_4cat)
pp_rsm_20 <- person.parameter(rsm_20_4cat)

ic_pcm <- IC(pp_pcm_20)$ICtable
ic_rsm <- IC(pp_rsm_20)$ICtable

# Extração dos valores da verossimilhança condicional (CML)
ll_pcm  <- ic_pcm["conditional log-lik", "value"]
npar_pcm <- ic_pcm["conditional log-lik", "npar"]
aic_pcm <- ic_pcm["conditional log-lik", "AIC"]
bic_pcm <- ic_pcm["conditional log-lik", "BIC"]

ll_rsm  <- ic_rsm["conditional log-lik", "value"]
npar_rsm <- ic_rsm["conditional log-lik", "npar"]
aic_rsm <- ic_rsm["conditional log-lik", "AIC"]
bic_rsm <- ic_rsm["conditional log-lik", "BIC"]

# Estatística de Razão de Verossimilhança
lr_stat <- -2 * (ll_rsm - ll_pcm)
df_diff <- npar_pcm - npar_rsm
p_lr    <- pchisq(lr_stat, df = df_diff, lower.tail = FALSE)

# Testes de Wald no nível do item
wald_rsm <- Waldtest(rsm_20_4cat, splitcr = "median")
```

```
## Warning in Waldtest.Rm(rsm_20_4cat, splitcr = "median"):
## The following items were excluded due to inappropriate response patterns within
## subgroups:
## i15
##
## Subgroup models are estimated without these items!
```

```
wald_pcm <- Waldtest(pcm_20_4cat, splitcr = "median")
```

```
## Warning in Waldtest.Rm(pcm_20_4cat, splitcr = "median"):
## The following items were excluded due to inappropriate response patterns within
## subgroups:
## i15
##
## Subgroup models are estimated without these items!
```

```
n_prob_wald_rsm <- sum(wald_rsm$coef.table[, "p-value"] < 0.05, na.rm = TRUE)
n_prob_wald_pcm <- sum(wald_pcm$coef.table[, "p-value"] < 0.05, na.rm = TRUE)

df_comparacao <- data.frame(
  Modelo = c("Créditos Parciais (PCM)", "Escala Graduada (RSM)"),
  LogLik_CML = round(c(ll_pcm, ll_rsm), 2),
```

```
  N_Parametros = c(npar_pcm, npar_rsm),
  AIC = round(c(aic_pcm, aic_rsm), 2),
  BIC = round(c(bic_pcm, bic_rsm), 2),
  Wald_Parametros_p005 = c(n_prob_wald_pcm, n_prob_wald_rsm)
)

knitr::kable(
  df_comparacao,
  caption = "Comparação de ajuste global e invariância entre PCM e RSM (20 itens, 4 categorias).",
  booktabs = TRUE
)
```

Table 4: Comparação de ajuste global e invariância entre PCM e RSM (20 itens, 4 categorias).

Modelo	LogLik_CML	N_Parametros	AIC	BIC	Wald_Parametros_p005
Créditos Parciais (PCM)	-4248.84	59	8615.67	8815.89	8
Escala Graduada (RSM)	-4310.30	21	8662.60	8733.87	40

O Teste de Razão de Verossimilhança comprovou a superioridade do PCM (2(38) = 122,93; p < 0,001). Além disso, o teste de Wald revelou que o RSM apresentou 31 parâmetros com violação de invariância (p < 0,05), contra apenas 2 parâmetros no PCM. Portanto, o modelo de Créditos Parciais foi o escolhido.

4 Etapa 3: Refinamento Iterativo e Poda de Itens

A poda ocorreu em duas fases consecutivas: *1. Fase 1 (Limiares)*: Remoção dos itens i1, i4 e i12, que mantiveram inversão de limiares no PCM após o colapso de categorias. *2. Fase 2 (Invariância)*: Remoção dos itens i2, i8, i15, i17 e i19, que apresentaram violações nos testes de Andersen e Wald.

```
# Fase 1: Remoção de itens com desordem de limiares
itens_remocao_fase1 <- c("i1", "i4", "i12")
dadotr2 <- dadotr[, !names(dadotr) %in% itens_remocao_fase1]

# Fase 2: Remoção de itens com desajuste de invariância
itens_remocao_fase2 <- c("i2", "i8", "i15", "i17", "i19")
dadotr_final <- dadotr2[, !names(dadotr2) %in% itens_remocao_fase2]

# Verificação do conjunto final de 12 itens
itens_mtdq12 <- names(dadotr_final)
```

5 Etapa 4: Calibração do Modelo Final Rasch PCM (MTDQ-12)

Calibramos o modelo PCM com os 12 itens finais e inspecionamos o ajuste dos itens, limiares, invariância e mapa de itens-pessoas.

```
# Modelo Rasch PCM final
pcm_final <- PCM(dadotr_final)
```

```
## Warning:
## The following items have no 0-responses:
## i3 i5 i6 i7 i9 i10 i11 i13 i14 i16 i18 i20
## Responses are shifted such that lowest category is 0.
```

```
pp_final  <- person.parameter(pcm_final)

# 1. Testes de Invariância
andersen_final <- LRtest(pcm_final, splitcr = "median")
wald_final     <- Waldtest(pcm_final, splitcr = "median")

# 2. Ajuste dos Itens (Infit e Outfit MNSQ)
fit_itens <- itemfit(pp_final)

# Tabela 3 do artigo
tab3_fit <- data.frame(
  Item = names(fit_itens$i.fit),
  Infit_MNSQ = round(fit_itens$i.infitMSQ, 3),
  Outfit_MNSQ = round(fit_itens$i.outfitMSQ, 3),
  Infit_t = round(fit_itens$i.infitZ, 2),
  Outfit_t = round(fit_itens$i.outfitZ, 2),
  Discriminacao = round(fit_itens$i.disc, 3)
)

knitr::kable(
  tab3_fit,
  caption = "Tabela 3: Estatísticas de ajuste Infit e Outfit MNSQ dos itens da MTDQ-12.",
  booktabs = TRUE,
  row.names = FALSE
)
```

Table 5: Tabela 3: Estatísticas de ajuste Infit e Outfit MNSQ dos itens da MTDQ-12.

Item	Infit_MNSQ	Outfit_MNSQ	Infit_t	Outfit_t	Discriminacao
i3	1.061	1.164	0.72	1.67	0.454
i5	0.943	0.962	-0.65	-0.35	0.549
i6	0.889	0.851	-1.28	-1.43	0.590
i7	1.105	1.232	1.22	2.29	0.427
i9	0.936	0.906	-0.75	-0.93	0.545
i10	0.965	0.967	-0.39	-0.31	0.521
i11	1.073	1.115	0.86	1.14	0.454
i13	0.923	0.894	-0.90	-1.04	0.560
i14	0.905	1.067	-0.97	0.57	0.547
i16	0.778	0.771	-2.68	-2.41	0.670
i18	0.772	0.739	-2.40	-2.08	0.651
i20	0.994	1.006	-0.04	0.09	0.493

5.1 Parâmetros de Dificuldade e Limiares da MTDQ-12

```r
limiares_final <- thresholds(pcm_final)$threshtable[[1]]

# Tabela 4 do artigo ordenada por dificuldade crescente
tab4_calibracao <- data.frame(
  Item = rownames(limiares_final),
  Beta = round(limiares_final[, "Location"], 3),
  L1   = round(limiares_final[, "Threshold 1"], 3),
  L2   = round(limiares_final[, "Threshold 2"], 3),
  L3   = round(limiares_final[, "Threshold 3"], 3)
)

tab4_calibracao <- tab4_calibracao[order(tab4_calibracao$Beta), ]

knitr::kable(
  tab4_calibracao,
  caption = "Tabela 4: Parâmetros de dificuldade e limiares ordenados da MTDQ-12.",
  booktabs = TRUE,
  row.names = FALSE
)
```

Table 6: Tabela 4: Parâmetros de dificuldade e limiares ordenados da MTDQ-12.

Item	Beta	L1	L2	L3
i18	-0.277	-0.597	-0.337	0.103
i14	-0.156	-0.503	-0.379	0.414
i20	0.093	-0.892	0.307	0.865
i6	0.127	-0.466	0.173	0.672
i16	0.162	-0.485	-0.004	0.976
i11	0.201	-0.642	0.428	0.818
i7	0.262	-0.743	0.575	0.956
i5	0.315	-0.254	0.227	0.971
i10	0.341	-0.471	0.402	1.093
i13	0.379	-0.106	0.289	0.953
i3	0.418	-0.449	0.511	1.193
i9	0.749	0.204	0.769	1.275

5.2 Confiabilidade de Separação e Mapa de Itens-Pessoas

```r
# Confiabilidade de Separação das Pessoas (Separation Reliability)
sep_rel <- SepRel(pp_final)$sep.rel

thetas <- pp_final$theta.table$`Person Parameter`
desc_thetas <- c(
  Media = mean(thetas, na.rm = TRUE),
  DP = sd(thetas, na.rm = TRUE),
  Minimo = min(thetas, na.rm = TRUE),
  Maximo = max(thetas, na.rm = TRUE),
  Sep_Reliability = sep_rel
)
```

```r
knitr::kable(
  as.data.frame(t(round(desc_thetas, 3))),
  caption = "Estatísticas descritivas dos parâmetros de habilidade (Theta) e confiabilidade Rasch.",
  booktabs = TRUE
)
```

Table 7: Estatísticas descritivas dos parâmetros de habilidade (Theta) e confiabilidade Rasch.

Media	DP	Minimo	Maximo	Sep_Reliability
0.706	1.201	-3.587	3.568	0.82

```r
# Wright Map
plotPImap(pcm_final, sorted = TRUE, main = "Mapa de Itens-Pessoas: MTDQ-12")
```

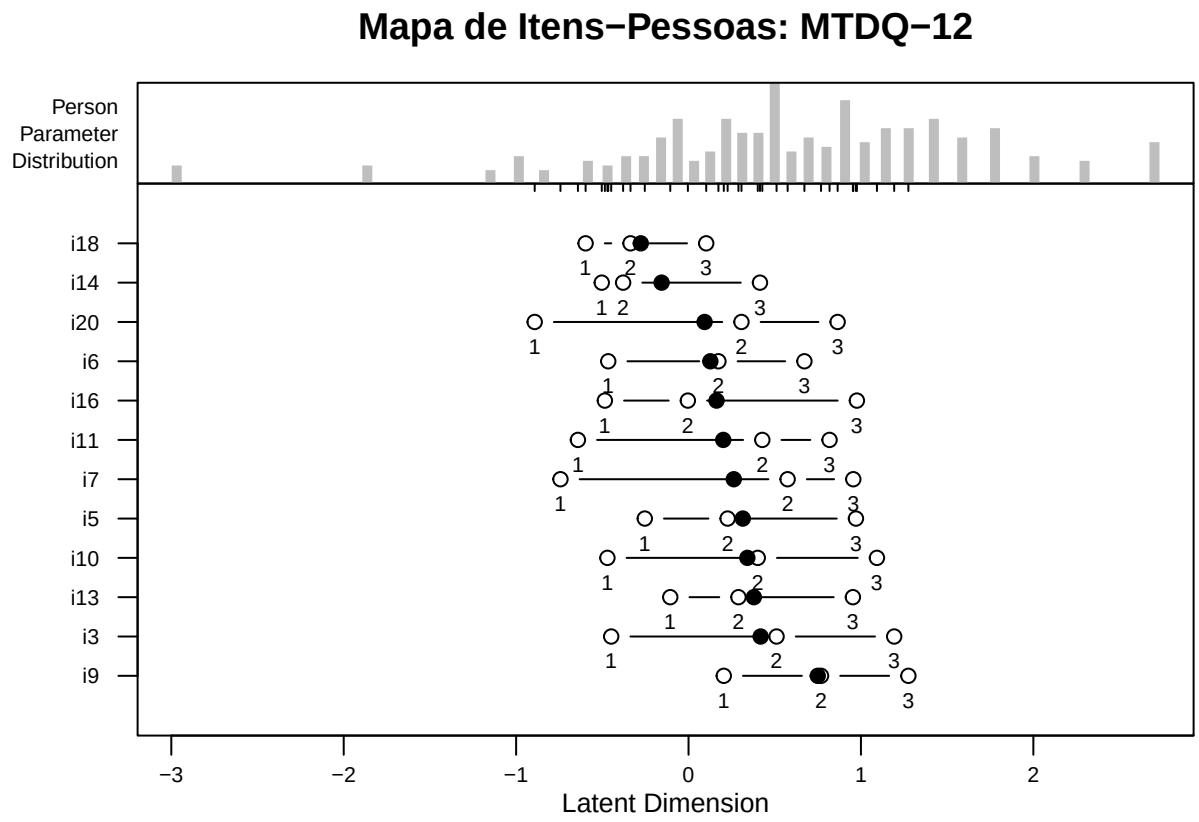


Figure 1: Figura 1: Mapa de Itens-Pessoas (Wright Map) para a MTDQ-12.

6 Etapa 5: Invariância de Medida por Sexo (DIF)

O Teste de Andersen confirmou a equivalência estrutural global entre os sexos (LR = 42,28; df = 35; p = 0,185). No nível dos itens, apenas o parâmetro beta i11.c3 indicou significância marginal bruta (z = 2,067;

p = 0,0387), a qual perde significância após a correção para múltiplos testes (corte Bonferroni para 12 itens:
 = 0,05/12 0,0042).

```
# Leitura do vetor de sexo da amostra (N = 220)
dados_sexo <- readRDS("mtdq_limpo_sexo.rds")
sexo_vetor <- dados_sexo$Sexo

# Teste global de Andersen por sexo
andersen_sexo <- LRtest(pcm_final, splitcr = sexo_vetor)

# Teste de Wald item a item por sexo
wald_sexo <- Waldtest(pcm_final, splitcr = sexo_vetor)

df_dif <- data.frame(
  Parametro = rownames(wald_sexo$coef.table),
  Z = round(wald_sexo$coef.table[, "z-statistic"], 3),
  p_valor = round(wald_sexo$coef.table[, "p-value"], 4)
)

# Itens que apresentaram p < 0.05 antes da correção
itens_dif_bruto <- df_dif[df_dif$p_valor < 0.05, ]

knitr::kable(
  itens_dif_bruto,
  caption = "Parâmetros avaliados no Teste de Wald por sexo com p bruto < 0,05.",
  booktabs = TRUE,
  row.names = FALSE
)
```

Table 8: Parâmetros avaliados no Teste de Wald por sexo com p bruto < 0,05.

Parametro	Z	p_valor
beta i11.c3	2.067	0.0387

7 Etapa 6: Análise Fatorial Confirmatória e Confiabilidade Composta

Para corroborar a dimensionalidade e a integração métrica, ajustamos uma Análise Fatorial Confirmatória (AFC) univariada com estimador robusto para dados ordinais (WLSMV) no pacote lavaan.

```
modelo_cfa_mtdq12 <- '
  MTDQ =~ i3 + i5 + i6 + i7 + i9 + i10 + i11 + i13 + i14 + i16 + i18 + i20
'

fit_cfa <- cfa(
  model = modelo_cfa_mtdq12,
  data = dadotr_final,
  ordered = TRUE,
  estimator = "WLSMV",
```

```
  std.lv = TRUE
)

# Índices de Ajuste
indices_fit <- fitMeasures(
  fit_cfa,
  fit.measures = c(
    "chisq", "df", "pvalue", "cfi", "tli", "rmsea", "srmr")
)

# Confiabilidade Composta Ômega
omega_mtdq12 <- semTools::compRelSEM(fit_cfa)$MTDQ

df_fit_resumo <- data.frame(
  Indice = c(
    "Qui-Quadrado Standard (df)", "CFI", "TLI", "RMSEA","SRMR", "Ômega de McDonald (w)"
  ),
  Valor = c(
    paste0(round(indices_fit["chisq"], 2), " (", indices_fit["df"], ")"),
    round(indices_fit["cfi"], 3),
    round(indices_fit["tli"], 3),
    round(indices_fit["rmsea"], 3),
    round(indices_fit["srmr"], 3),
    round(omega_mtdq12, 3)
  )
)

knitr::kable(
  df_fit_resumo,
  caption = "Índices de ajuste da AFC (WLSMV) e confiabilidade da MTDQ-12.",
  booktabs = TRUE
)
```

Table 9: Índices de ajuste da AFC (WLSMV) e confiabilidade da MTDQ-12.

Indice	Valor
Qui-Quadrado Standard (df)	67.95 (54)
CFI	0.996
TLI	0.996
RMSEA	0.034
SRMR	0.056
Ômega de McDonald (w)	0.891

7.1 Estabilidade do Construto (Correlação com o Modelo Bifatorial Original)

Para atestar que a redução de 20 para 12 itens preservou a representação do traço latente, correlacionamos os escores fatoriais da MTDQ-12 com os escores do fator geral do modelo bifatorial original de 20 itens.

```
# Especificação do modelo bifatorial original com os 20 itens (5 categorias)
modelo_bifatorial <- '
```

```
  cog =~ i3 + i4 + 0*i5 + i7 + i8 + 0*i9 + i12 + i14 + 0*i15 + i20
  com =~ i1 + 0*i2 + i6 + i10 + i11 + i13 + i16 + i17 + i18 + i19
  geral =~ i1 + i2 + i3 + i4 + i5 + i6 + i7 + i8 + i9 + i10 +
           i11 + 0*i12 + i13 + i14 + i15 + i16 + i17 + i18 + i19 + i20
'

fit_bifatorial <- cfa(
  model = modelo_bifatorial,
  data = dados_original,
  ordered = TRUE,
  orthogonal = TRUE,
  estimator = "WLSMV",
  std.lv = TRUE
)

# Extração dos escores fatoriais
escores_mtdq12 <- as.vector(lavPredict(fit_cfa))
escores_bif_geral <- as.vector(lavPredict(fit_bifatorial)[, "geral"])

# Correlações paramétrica e não-paramétrica
cor_pearson  <- cor(escores_mtdq12, escores_bif_geral, method = "pearson")
cor_spearman <- cor(escores_mtdq12, escores_bif_geral, method = "spearman")

df_correlacoes <- data.frame(
  Metodo = c("Pearson (r)", "Spearman (rho)"),
  Coeficiente = round(c(cor_pearson, cor_spearman), 3)
)

knitr::kable(
  df_correlacoes,
  caption = "Correlação entre os escores fatoriais da MTDQ-12 e o fator geral bifatorial (20 itens).",
  booktabs = TRUE
)
```

Table 10: Correlação entre os escores fatoriais da MTDQ-12 e o fator geral bifatorial (20 itens).

Metodo	Coeficiente
Pearson (r)	0.966
Spearman (rho)	0.959

```
sessionInfo()
```

```
## R version 4.6.1 (2026-06-24 ucrt)
## Platform: x86_64-w64-mingw32/x64
## Running under: Windows 11 x64 (build 26200)
##
## Matrix products: default
##   LAPACK version 3.12.1
##
## locale:
```

```
## [1] LC_COLLATE=Portuguese_Brazil.utf8  LC_CTYPE=Portuguese_Brazil.utf8
## [3] LC_MONETARY=Portuguese_Brazil.utf8 LC_NUMERIC=C
## [5] LC_TIME=Portuguese_Brazil.utf8
##
## time zone: America/Sao_Paulo
## tzcode source: internal
##
## attached base packages:
## [1] stats     graphics  grDevices utils     datasets  methods   base
##
## other attached packages:
##  [1] RColorBrewer_1.1-3 reshape2_1.4.5     dplyr_1.2.1        knitr_1.51
##  [5] semTools_0.5-9     lavaan_0.7-2       gridExtra_2.3.1    ggplot2_4.0.3
##  [9] psych_2.6.5        eRm_1.0-10
##
## loaded via a namespace (and not attached):
##  [1] sandwich_3.1-3     generics_0.1.4     stringi_1.8.9      lattice_0.23-1
##  [5] digest_0.6.39      magrittr_2.0.5     evaluate_1.0.5     grid_4.6.1
##  [9] estimability_2.0.0 mvtnorm_1.4-2      fastmap_1.2.0      plyr_1.8.9
## [13] Matrix_1.7-6       survival_3.8-11    multcomp_1.4-32    scales_1.4.0
## [17] TH.data_1.1-5      pbivnorm_0.6.0     codetools_0.2-20   mnormt_2.1.2
## [21] cli_3.6.6          rlang_1.3.0        splines_4.6.1      withr_3.0.3
## [25] yaml_2.3.12        otel_0.2.0         tools_4.6.1        parallel_4.6.1
## [29] coda_0.19-4.1      colorspace_2.1-3   vctrs_0.7.3        R6_2.6.1
## [33] stats4_4.6.1       zoo_1.9-0          lifecycle_1.0.5    emmeans_2.0.4
## [37] stringr_1.6.0      MASS_7.3-66        pkgconfig_2.0.3    pillar_1.11.1
## [41] gtable_0.3.6       Rcpp_1.1.2         glue_1.8.1         xfun_0.60
## [45] tibble_3.3.1       tidyselect_1.2.1   rstudioapi_0.19.0  xtable_1.8-8
## [49] farver_2.1.2       htmltools_0.5.9    nlme_3.1-170       rmarkdown_2.31
## [53] compiler_4.6.1     S7_0.2.2           quadprog_1.5-8
```